

Wykład 6 RNN i zanikające gradienty

Sieci RNN umożliwiają modelowanie zależnych od czasu i sekwencyjnych zadań związanych z danymi. Jednak przy stosowaniu RNN występuje problem zanikających gradientów, co utrudnia uczenie się długich sekwencji danych. Gradienty przenoszą informacje wykorzystywane w aktualizacji parametrów RNN, a gdy gradient staje się coraz mniejszy, aktualizacje parametrów stają się nieistotne,

Przypomnijmy krótko, jak wyglądają sieci RNN. Obliczenia zostaną przeprowadzone na prostym modelu RNN z pojedynczą ukrytą warstwą z pojedynczą sekwencją wyjściową. Sieć wygląda tak




Fig. 1. Model sieci RNN

Sieć ma wejściowy ciąg wektorów $(x_1, x_2, \dots, x_k)$, w chwili czasu t sieć ma wejściowy wektor x_t . Informacje przeszłe i zdobyta wiedza są zakodowane w wektorach stanu sieci $(c_1, c_2, \dots, c_k)$, w chwili czasu t sieć ma wektor stanu c_{t-1} . Wektor wejściowy x_t i wektor stanu c_{t-1} są łączone, tworząc kompletny wektor wejściowy w chwili czasu t , informacja wejściowa wynosi (c_{t-1}, x_t) .

Sieć ma dwie macierze wag: W_c i W_x łączące c_{t-1} i x_t , dwie części wektora wejściowego (c_{t-1}, x_t) , z warstwą ukrytą. Dla uproszczenia pomijamy wektory obciążeń w naszych obliczeniach i oznaczamy $W = (W_c, W_x)$.

Funkcja sigmoidalna jest używana jako funkcja aktywacji w warstwie ukrytej. Sieć wyprowadza pojedynczy wektor w ostatnim kroku czasowym (RNN mogą generować wektor w każdym kroku czasowym, ale użyjemy tego prostszego modelu).

Propagacja wsteczna w czasie (BPTT) w sieciach RNN

Po tym, jak w procesie propagacji w RNN obliczymy wektor predykcji $h(k)$, jesteśmy zainteresowani błędem predykcji $E(k)$ (inne oznaczenie funkcji straty $L(k)$). Do jego minimalizacji używamy gradient, w tym celu wykorzystywany jest algorytm propagacji wstecznej w czasie (Rumelhart, D., Hinton, G. & Williams, R., 1986). W sieci rekurencyjnej błąd liczony jest w każdym punkcie czasowym. Dlatego gradient liczony jest wg wzoru

$$\frac{\partial E}{\partial W} = \sum_{t=1}^T \frac{\partial E_t}{\partial W}$$

Gradient służy do aktualizacji parametrów modelu poprzez proces uczenia za pomocą algorytmu Gradient Descent (GD) (używamy podstawowej wersji GD).

$$W \leftarrow W - \alpha \frac{\partial E}{\partial W}$$

Mamy zadanie nauczania, które obejmuje T kroków czasowych, gradient błędu w kroku czasowym k jest określony wzorem:

$$\begin{aligned} \frac{\partial E_k}{\partial W} &= \frac{\partial E_k}{\partial h_k} \frac{\partial h_k}{\partial c_k} \cdots \frac{\partial c_2}{\partial c_1} \frac{\partial c_1}{\partial W} \\ &= \frac{\partial E_k}{\partial h_k} \frac{\partial h_k}{\partial c_k} \left(\prod_{t=2}^k \frac{\partial c_t}{\partial c_{t-1}} \right) \frac{\partial c_1}{\partial W} \end{aligned}$$

Zauważ, że ponieważ $W = [W_c, W_x]$, c_t można zapisać jako

$$c_t = \sigma(W_c \cdot c_{t-1} + W_x x_t)$$

Pochodna, c_t wynosi

$$\begin{aligned} \frac{\partial c_t}{\partial c_{t-1}} &= \sigma'(W_c \cdot c_{t-1} + W_x x_t) \cdot \frac{\partial}{\partial c_{t-1}} (W_c \cdot c_{t-1} + W_x x_t) \\ &= \sigma'(W_c \cdot c_{t-1} + W_x x_t) \cdot W_c \end{aligned}$$

Propagacja wsteczna gradient

$$\frac{\partial E_k}{\partial W} = \frac{\partial E_k}{\partial h_k} \frac{\partial h_k}{\partial c_k} \left(\prod_{t=2}^k \sigma'(W_c \cdot c_{t-1} + W_x x_t) \cdot W_c \right) \frac{\partial c_t}{\partial W}$$

Ostatnie wyrażenie ma tendencję do zanikania, gdy k jest duże, wynika to z pochodnej funkcji aktywacji $\tanh()$, która jest mniejsza od 1.

Produkt pochodnych może również eksplodować jest to znane jako problem eksplodującego gradientu.

Jeżeli mamy

$$\prod_{t=2}^k \sigma'(W_c \cdot c_{t-1} + W_x x_t) \cdot W_c \rightarrow 0$$

wówczas oznacza to, że dla jakiegoś kroku k

$$\frac{\partial E_k}{\partial W} \rightarrow 0$$

nasz całkowity gradient błędów zniknie

$$\frac{\partial E}{\partial W} = \sum_{t=1}^T \frac{\partial E_t}{\partial W} \rightarrow 0$$

i aktualizacja wag sieci będzie wyglądać następująco

$$W \leftarrow W - \alpha \frac{\partial E}{\partial W} \approx W$$

żadna znacząca nauka nie zostanie dokonana w rozsądnym czasie.

LSTM jako udoskonalenie sieci RNN

Pomysł długoterminowej pamięci sieci został wprowadzony przez Hochreiter w 1991 w jego pracy dyplomowej, jednakże pierwsza publikacja dotycząca sieci LSTM pochodzi z roku 1997 i jest autorstwa Hochreitera i Schmidhubera (Hochreiter, S. and Schmidhuber, J., 1997). Model sieci LSTM został wprowadzony jako udoskonalenie sieci RNN, w których przy długich sekwencjach danych, mogących mieć długość setek a nawet tysięcy kroków, pojawiał się problem znikających bądź eksplodujących gradientów opisany przez Bangio et al. w 1994 (Bengio, Y., P. Simard, P. and Frasconi, P., 1994). W modelu LSTM zawarte są specjalne komórki zdolne do uczenia się długotrwałych zależności [48]. Architektura sieci LSTM oparta jest na 3 rodzajach bramek, które aktualizują i kontrolują stany komórek, są to forget gate, input gate and output gate (bramka zapominająca, bramka wejściowa i bramka wyjściowa). Bramki wykorzystują funkcje aktywacji tangensa hiperbolicznego i sigmoidalnej.

Sieć LSTM ma wektor wejściowy w momencie czasu t : (h_{t-1}, x_t) , gdzie h_{t-1} jest stanem wyjściowym poprzedniej komórki (czyli w chwili $t - 1$). Stan komórki sieciowej jest oznaczony przez c_t . Wektory wyjściowe przechodzące przez sieć pomiędzy kolejnymi chwilami czasowymi $t, t + 1$ oznaczamy przez h_t .




Fig.2. Komórki sieci LSTM w chwilach czasowych: $(t - 1)$, (t) , $(t + 1)$

Sieć LSTM ma trzy bramki, które aktualizują i kontrolują stany komórek, są to **forget gate**, **input gate** and **output gate** (bramka zapominająca, bramka wejściowa i bramka wyjściowa). Bramki wykorzystują funkcje aktywacji tangensa hiperbolicznego i sigmoidalnej.

Bramka zapominania kontroluje, jakie informacje ze stanu komórki mają zostać zapomniane, biorąc pod uwagę nowe informacje niż te już wprowadzone do komórki.

1. Wyjście bramki zapominania jest definiowane przez:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t])$$

Bramka zapominania to warstwa sigmoidalna, która służy do zapominania nieistotnych informacji historycznych. Została wprowadzona w 1999 r. w celu poprawienia niedoskonałości sieci LSTM [47].

2. **Bramka wejściowa** kontroluje, jakie nowe informacje zostaną zakodowane w stanie komórki, biorąc pod uwagę nowe informacje wejściowe.

Wyjście bramki wejściowej jest definiowane przez

$$\tanh(W_c \cdot [h_{t-1}, x_t]) \circ \sigma(W_i \cdot [h_{t-1}, x_t])$$

Operator $\circ$ jest równy iloczynowi odpowiadających elementów (element-wise) wyjść dwóch w pełni połączonych warstw $\tilde{c}_t$ oraz i_t :

$$\tilde{c}_t = \tanh(W_c \cdot [h_{t-1}, x_t])$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t])$$

3. Bramka wyjściowa kontroluje, jakie informacje zakodowane w stanie komórki są wysyłane do sieci jako dane wejściowe w kolejnym kroku czasowym, odbywa się to za pośrednictwem wektora wyjściowego h_t .

Wyjście bramki wyjściowej jest definiowane przez

$$\sigma_t = \sigma(W_o \cdot [h_{t-1}, x_t])$$

a wektor wyjściowy komórki jest określony przez:

$$h_t = \sigma_t \circ \tanh(c_t)$$

4. Długoterminowe zależności i relacje są zakodowane w wektorach stanu komórki. Pochodna stanu komórki może zapobiec zanikowi gradientów LSTM. Stan komórki LSTM ma postać:

$$c_t = c_{t-1} \circ f_t + \tilde{c}_t \circ i_t$$

Propagacja wsteczna w czasie w sieci LSTM

Podobnie jak w modelu RNN, sieć LSTM wyprowadza wektor predykcji h_k w k -tej chwili czasowej. Wiedza zakodowana w wektorach stanu c_t utrwała długoterminowe zależności i relacje w danych sekwencyjnych.

Sekwencje danych mogą mieć długość setek, a nawet tysięcy kroków czasowych, co sprawia, że przy użyciu podstawowego modelu RNN napotkamy problem obliczeniowe.

Gradient używany do aktualizacji parametrów sieci, jest obliczany w każdym z T kroków czasowych.




Fig. 3. Propagacja wsteczna w czasie do obliczeniach gradientu

Podobnie jak w RNN, gradient składników błędu jest określony przez następującą sumę T sub-gradientów

$$\frac{\partial E}{\partial W} = \sum_{t=1}^T \frac{\partial E_t}{\partial W}$$

Aby zniknął gradient błędów, wszystkie te sub-gradientsy T muszą zniknąć. Szereg ten jest zbieżny do zera, jeśli sekwencja jego sum cząstkowych dąży do zera,

$$\sum_{t=1}^T \frac{\partial E_t}{\partial W} \rightarrow 0 \text{ oznacza, że } \forall n > N_0 \sum_{t=1}^n \frac{\partial E_t}{\partial W} \rightarrow 0$$

Więc jeśli chcemy, aby gradient nie zniknął, nasza sieć musi zwiększyć prawdopodobieństwo, że przynajmniej niektóre z sub-gradientów nie znikną, innymi słowy, seria sub-gradientów nie może być zbieżna do zera

Gradienty błędów w sieci LSTM

Gradient błędu dla chwili czasowej k ma postać:

$$\begin{aligned} \frac{\partial E_k}{\partial W} &= \frac{\partial E_k}{\partial h_k} \frac{\partial h_k}{\partial c_k} \dots \frac{\partial c_2}{\partial c_1} \frac{\partial c_1}{\partial W} \\ &= \frac{\partial E_k}{\partial h_k} \frac{\partial h_k}{\partial c_k} \left(\prod_{t=2}^k \frac{\partial c_t}{\partial c_{t-1}} \right) \frac{\partial c_1}{\partial W} \end{aligned}$$

zniknięcie gradientów powoduje następujący wyraz:

$$\prod_{t=2}^k \frac{\partial c_t}{\partial c_{t-1}}$$

W sieci LSTM wektor stanu c_t ma postać:

$$c_t = c_{t-1} \circ f_t + \tilde{c}_t \circ i_t$$

$$c_t = c_{t-1} \circ \sigma(W_f \cdot [h_{t-1}, x_t]) + \tanh(W_c \cdot [h_{t-1}, x_t]) \circ \sigma(W_i \cdot [h_{t-1}, x_t])$$

wektor stanu c_t jest funkcją następujących elementów, które należy wziąć pod uwagę przy obliczaniu pochodnej podczas propagacji wstecznej: $c_{t-1}, f_t, \tilde{c}_t, i_t$.

Pochodna $\frac{\partial c_t}{\partial c_{t-1}}$ wynosi:

$$\begin{aligned}\frac{\partial c_t}{\partial c_{t-1}} &= \frac{\partial}{\partial c_{t-1}} [c_{t-1} \circ f_t + \tilde{c}_t \circ i_t] \\ &= \frac{\partial}{\partial c_{t-1}} [c_{t-1} \circ f_t] + \frac{\partial}{\partial c_{t-1}} [\tilde{c}_t \circ i_t] \\ &= \frac{\partial f_t}{\partial c_{t-1}} c_{t-1} + \frac{\partial c_{t-1}}{\partial c_{t-1}} f_t + \frac{\partial i_t}{\partial c_{t-1}} \tilde{c}_t + \frac{\partial \tilde{c}_t}{\partial c_{t-1}} i_t\end{aligned}$$

Obliczamy cztery wyrazy pochodne i piszemy

$$\begin{aligned}\frac{\partial c_t}{\partial c_{t-1}} &= \sigma'(W_t[h_{t-1}, x_t]) \cdot W_f \cdot \sigma_t \circ \tanh' h(c_{t-1}) \cdot c_{t-1} \\ &\quad + f_t \\ &\quad + \sigma'(W_i[h_{t-1}, x_t]) \cdot W_i \cdot \sigma_{t-1} \circ \tanh' h(c_{t-1}) \cdot \tilde{c}_t \\ &\quad + \sigma'(W_c[h_{t-1}, x_t]) \cdot W_c \cdot \sigma_{t-1} \circ \tanh' h(c_{t-1}) \cdot \tilde{i}_t\end{aligned}$$

Oznaczmy teraz:

$$\begin{aligned}A_t &\equiv \sigma'(W_t[h_{t-1}, x_t]) \cdot W_f \cdot \sigma_t \circ \tanh' h(c_{t-1}) \cdot c_{t-1} \\ B_t &\equiv f_t \\ C_t &\equiv \sigma'(W_i[h_{t-1}, x_t]) \cdot W_i \cdot \sigma_{t-1} \circ \tanh' h(c_{t-1}) \cdot \tilde{c}_t \\ D_t &\equiv \sigma'(W_c[h_{t-1}, x_t]) \cdot W_c \cdot \sigma_{t-1} \circ \tanh' h(c_{t-1}) \cdot \tilde{i}_t\end{aligned}$$

wówczas możemy zapisać

$$\frac{\partial c_t}{\partial c_{t-1}} = A_t + B_t + C_t + D_t$$

co daje

$$\frac{\partial E_k}{\partial W} = \frac{\partial E_k}{\partial h_k} \frac{\partial h_k}{\partial c_k} \left(\prod_{t=2}^k [A_t + B_t + C_t + D_t] \right) \frac{\partial c_1}{\partial W}$$

Gradient zawiera wektor aktywacji bramki zapominania, co pozwala sieci lepiej kontrolować wartości sub-gradientów w każdej chwili czasowej, wykorzystując odpowiednie aktualizacje parametrów bramki zapominania.

Obecność bramki zapominania pozwala w sieci LSTM na podjęcie decyzji, w każdej chwili czasowej, że pewnych informacji nie należy zapominać i odpowiednio zaktualizować parametry modelu.

Aby gradient nie zniknął, możemy znaleźć odpowiednią aktualizację parametru bramki zapominania w chwili czasowej $k + 1$ taką, że:

$$\frac{\partial E_{k+1}}{\partial W} \rightarrow 0$$

a co za tym idzie

$$\sum_{t=1}^{k+1} \frac{\partial E_t}{\partial W} \nrightarrow 0$$

i gradient nie znika.

Inną ważną właściwością, na którą należy zwrócić uwagę, jest to, że gradient stanu komórki jest funkcją addytywną składającą się z czterech elementów oznaczonych A_t, B_t, C_t, D_t . Ta addytywna właściwość umożliwia lepsze równoważenie wartości gradientu podczas wstecznej propagacji. Sieć LSTM aktualizuje i równoważy wartości czterech składników, zwiększając prawdopodobieństwo, że addytywne wyrażenie nie zniknie.

Ta właściwość addytywna różni LSTM od przypadku RNN, w którym gradient zawierał pojedynczy element wewnątrz produktu. W RNN suma $\sum_{t=1}^T \frac{\partial E_t}{\partial W}$ jest tworzona z wyrażeń o podobnym zachowaniu, których wartość zawiera się w przedziale $[0,1]$, co powoduje znikanie gradientu.

W LSTM obecność bramki zapominającej wraz z addytywną właściwością gradientów stanu komórki umożliwia sieci aktualizację parametrów w taki sposób, że różne subgradienty $\frac{\partial E_k}{\partial W}$ niekoniecznie zachowują się w podobny sposób, zmniejszając prawdopodobieństwo, że wszystkie sub-gradienty znikną, czyli innymi słowy, szereg funkcji nie musi zbiegać do zera.

Technika drop-out

W sieciach neuronowych regularyzacja to technika modyfikacji algorytmu trenowania, która zmniejsza błąd generalizacji poprzez zwiększenie błędu uczenia na konkretnej próbce. Popularną techniką regularyzacji jest drop-out.

Standardowa metoda drop-out polega na modyfikacji sieci poprzez wyłączanie losowo wybranych neuronów podczas treningu.. Neurony są usuwane podczas uczenia i