

Ćw. 8 Pobieranie zbiorów danych i wysyłanie plików csv na urządzenie lokalne

<https://www.geeksforgeeks.org/how-to-download-kaggle-datasets-into-jupyter-notebook/>

Pobranie danych Kaggle za pomocą Jupyter Notebook.

Dwie różne metody rozpoczęcia pracy z Jupyter Notebook.

Metoda 1

W pierwszej metodzie użyjemy interfejsu API Kaggle do pobrania naszego zestawu danych, a następnie możemy zacząć korzystać z naszego zestawu danych. W innej metodzie ręcznie pobieramy dane z witryny Kaggle i używamy naszego zestawu danych do produkcji lub analizy danych.

Metoda 1: Pobieranie zestawu danych Kaggle w Jupyter Notebook

Krok 1: Pobierz i zainstaluj wymagane pakiety.

```
pip install opendatasets
```

```
pip install pandas
```

Krok 2: Odwiedź stronę www.kaggle.com. Przejdź do swojego profilu i kliknij konto.

Krok 3: Na następnej stronie zobaczysz sekcję API, w której znajdziesz „Create New API Token”, kliknij na nią, a zostanie pobrany plik kaggle.json, w którym otrzymasz nazwę użytkownika i klucz. użyjemy nazwy użytkownika i klucza w następnym kroku.

Krok 4: Otwórz notatnik Jupyter, zaimportuj bibliotekę opendatasets i pobierz zestaw danych Kaggle, wklejając link do niego.

```
import opendatasets as od
```

```
import pandas
```

```
od.download("https://www.kaggle.com/datasets/.....dataset")
```

Output:

```
In [*]: import opendatasets as od
import pandas

od.download(
    "https://www.kaggle.com/datasets/muratkokludataset/acoustic-extinguisher-fire-dataset")

Please provide your Kaggle credentials to download this dataset. Learn more: http://bit.ly/kaggle-creds
Your Kaggle username: surjkr
Your Kaggle Key:

```

Metoda 2: Ręczne pobieranie zestawu danych Kaggle

Krok 1: Odwiedź stronę Kaggle i wybierz zakładkę Dataset.



Krok 2: Wybierz dowolny zestaw danych i kliknij Pobierz.


Krok 3: Pobrany plik będzie w formacie Zip, rozpakuj go.

Krok 4: Prześlij do swojego notatnika Jupyter.


Pobieranie projektów z Githuba

https://www.youtube.com/watch?v=eWiPHP0us_0





File clone repository



Pliki tar.gz

<https://informatyk.pro/zip-tar-tar-gz-jak-spakowac-i-rozpakowywac-pliki-na-serwerze/>

```
!wget -cq https://github.com/udacity/pytorch_challenge/raw/master/cat_to_name.json
!wget -cq https://s3.amazonaws.com/content.udacity-data.com/nd089/flower_data.tar.gz
```

```
import tarfile
tar = tarfile.open("flower_data.tar.gz")
tar.extractall()
tar.close()
```

```
!ls
```

```
cat_to_name.json  flower_data.tar.gz  sample_data  test  train  valid
```

```
!rm -r flower_data.tar.gz
```

Przygotowanie danych do pracy w Azure

```
import torch
import matplotlib.pyplot as plt
from sklearn.datasets import make_blobs
from sklearn.model_selection import train_test_split
import pandas as pd
import numpy as np

# Zdefiniuj parametry (można zmienić, np dać 5 klas)
NUM_CLASSES = 2
NUM_FEATURES = 4
RANDOM_SEED = 42

# 1. Utworzenie danych
X_blob, y_blob = make_blobs(n_samples=1000,
                             n_features=NUM_FEATURES, # X cechy
                             centers=NUM_CLASSES, # y etykiety
                             cluster_std=1.5, # lekko wstrząśnij klastrami (spróbuj zmienić wartość domyślną na 1,0)
                             random_state=RANDOM_SEED
)

Data = np.concatenate([X_blob, y_blob.reshape(-1,1)], axis=1) # Reshape y_blob to have 2 dim

# Konwersja danych do pandas DataFrame dla łatwiejszej obsługi
Data = pd.DataFrame(Data)

# Korzystanie z to_csv
Data.to_csv('data.csv', index=False) # Zapisanie pliku 'data.csv'

print(Data)
```

Przerzucenie danych utworzonych w Colabie na dysk lokalny lub Google Drive

```
import os
import pandas as pd

# ... (your existing code) ...

# Define the directory path
dir_path = r'C:/.....'

# Create the directory if it doesn't exist
if not os.path.exists(dir_path):
    os.makedirs(dir_path)
    print(f"Directory created: {dir_path}")
else:
    print(f"Directory already exists: {dir_path}")

# Now you can use to_csv
Data.to_csv(os.path.join(dir_path, 'Data.csv'), index=False, header=True)
```