

Ćw. 9

W ramach ćwiczeń przewidywane są 3 aktywności:


- Budowa modelu regresji liniowej do przewidywania cen samochodów z możliwością wdrożenia.
- Czyszczenie tekstu w ramach potoku Azure ML;
- Wykorzystanie kodu (model klasyfikacji Iris, dane Iris.csv)

UWAGA!

Po zakończeniu zadania należy usunąć grupę zasobów

1. Wdrożenie modelu w Azure na przykładzie przewidywania cen aut.

Budujemy model regresji. Zmienna celu jest typu ciągłego. Zbiór danych jest **zbiorem Azure**.



Select columns

Wybierz kolumny ☐ Z regułami ☒ Według nazwy

Dostępne kolumny	Wybrane kolumny
Wszystkie typy Wyszukaj 26 Kolumny Dodaj wszystko symboling + normalized-losses + make	Wszystkie typy Wyszukaj 0 Kolumny Usuń wszystko

Usuwamy normalized-losses bo ma dużo braków danych i symboling.

Wybierz kolumny ☐ Z regułami ☒ Według nazwy

Dostępne kolumny	Wybrane kolumny
Wszystkie typy Wyszukaj 1 Kolumny Dodaj wszystko normalized-losses +	Wszystkie typy Wyszukaj 25 Kolumny Usuń wszystko symboling — make — fuel-type — aspiration —

Clean Missing Data



Columns to be cleaned ⓘ *

[Edytuj kolumnę](#)

Nazwy kolumn: bore,stroke,horsepower

Minimum missing value ratio ⓘ *

...

0.0

Maximum missing value ratio ⓘ *

...

1.0

Cleaning mode ⓘ *

...

Remove entire row



Zmienne do normalizacji (wprowadzamy oddzielone przecinkami)

wheel-base, length, width, height, curb-weight, engine-size, bore, stroke, compression-ratio, horsepower, peak-rpm, city-mpg, highway-mpg

Normalize Data



Transformation method ⓘ *

...

MinMax

Use 0 for constant columns when checke... ⓘ *


...


True


Columns to transform ⓘ *

[Edytuj kolumnę](#)

Nazwy kolumn: wheel-base,length,width,height,curb-weight,engine-size,bore,stroke,compression-ratio,horsepower,peak-rpm,city-mpg,highway-mpg








Wiersze [?](#) Kolumny [?](#)


1 5

Mean_Absolute_Error	Root_Mean_Squared_Error	Relative_Squared_Error	Relative_Absolute_Error	Coefficient_of
1772.364487	2579.327479	0.099277	0.313408	0.900723

Tworzenie potoku w czasie rzeczywistym



Pojawia się nowe okienko



The 'Enter Data Manually' dialog box is shown. It contains the following fields:

- Data format**: Set to CSV.
- Has header**: Set to True.
- Data**: Set to 1.

Wprowadzamy swoje dane w formacie CSV (oddzielone przecinkami, bez ceny auta), usuwamy dane wejściowe i price z **Select Columns in Dataset**

Np. dane

symboling,normalized-losses,make,fuel-type,aspiration,num-of-doors,body-style,drive-wheels,engine-location,wheel-base,length,width,height,curb-weight,engine-type,num-of-cylinders,engine-size,fuel-system,bore,stroke,compression-ratio,horsepower,peak-rpm,city-mpg,highway-mpg

3,NaN,alfa-romero,gas,std,two,convertible,rwd,front,88.6,168.8,64.1,48.8,2548,dohc,four,130,mpfi,3.47,2.68,9,111,5000,21,27

1,NaN,alfa-romero,gas,std,two,hatchback,rwd,front,94.5,171.2,65.5,52.4,2823,ohcv,six,152,mpfi,2.68,3.47,9,154,5000,19,26

2,164,audi,gas,std,four,edan,fwd,front,99.8,176.6,66.2,54.3,2337,ohc,four,109,mpfi,3.19,3.4,10,102,5500,24,30

2,NaN,audi,gas,std,two,edan,fwd,front,99.8,177.3,66.3,53.1,2507,ohc,five,136,mpfi,3.19,3.4,8.5,110,5500,19,25

Usuamy Evaluate Model i dodajemy okienko Execute Python Script


```
import pandas as pd
```

```
def azureml_main(dataframe1=None, dataframe2= None):
```

```
    scored_results=dataframe1[['Scored Labels']]
```

```
    scored_results.rename(columns={'Scored Labels':'predicted_price'}, inplace=True)
```

```
    return scored_results
```




Wynik w Execute Python Script:

Podgląd danych > Result dataset

Result_Dataset ✕

Wiersze ? Kolumny ?

4 1





Pokaż listę porównań



Wdróż

Punkty końcowe

The screenshot shows the Azure portal interface. On the left, there's a sidebar with a search bar and a list of resources: Notebooks, Zautomatyzowane uczenie, Projektant, Przepływ monitorów, Zasoby, Dane, Zadania (job), Składniki, Potoki, Środowiska, Modele, and Punkty końcowe (selected). The main content area is titled 'Punkty końcowe' and has a sub-header 'Punkty końcowe w czasie rzeczywistym'.

Model staje się instancją kontenera Azure

Wyniki

The screenshot shows the 'Szczegóły' (Details) tab for an endpoint. It displays the following attributes:

Atrybuty punktu końcowego
Identyfikator usługi
cenyaut
Opis
--
Stan wdrożenia

Stan nieprawidłowy oznacza, że usługa została wdrożona, ale jest obecnie nieosiągalna.


[Dowiedz się więcej o stanach punktów końcowych](#)

UWAGA!

Proces długo trwa. Nawet 20 minut. Do tego czasu, Stan wdrożenia jest: **Unhealthy**


2. Czyszczenie tekstu.

Wykorzystaj Azure ML Studio do wyczyszczenia tekstu **Methamorphosis**. Tekst wprowadź jako plik CSV.





3. Wykorzystywanie kodu w Azure ML Studio

a. Przekazywanie notesu




b. Uruchamianie wystąpienia obliczeniowego z wersją Pythona





Niestety, uruchomienie prostego kodu wymaga instalacji niezbędnych bibliotek. Jest to dość kłopotliwe. Nie zawsze zainstalowane wersje są zgodne.



c) Po zakończeniu pracy należy wyłączyć sesje obliczeniowe!!! I zamknąć środowisko obliczeniowe i usunąć swoją grupę zasobów (Resource group).



Zarządzanie sesjami dla zasobów obliczeniowych „p4890001”

```
from azureml.core import Workspace, Datastore, Dataset
ws = Workspace.from_config()
dataset=Dataset.get_by_name(ws, name='Iris')
df=dataset.to_pandas_dataframe()
```

