


Ćw. 11 Równania Bellmana. Algorytm iteracji wartości

1. Opis do notatnika Równania Bellmana ([01 Gentle introduction to the Bellman equation \(1\).ipynb](#)) Proszę w domu obejrzeć filmy na youtube:

<https://www.youtube.com/watch?v=ookYeokJPiA&t=28s>

<https://www.youtube.com/watch?v=Up6XSRWlcb4&t=18s>

Cel: wyznaczenie wartości stanów dla danej strategii



Wyprowadzenie równań Bellmana dla przykładu świata na siatce Kamili Zdybał.

$$s_1 = (0,0), s_2 = (0,1), s_3 = (0,2)$$

$$s_4 = (1,0), s_5 = (1,1), s_6 = (1,2)$$

Strzałki oznaczają podejmowane akcje. Akcje są deterministyczne. Mamy

$$V_{\pi}(s_1) = R(s_1) + \gamma V_{\pi}(s_2)$$

$$V_{\pi}(s_2) = R(s_1) + \gamma V_{\pi}(s_3)$$

$$V_{\pi}(s_3) = R(s_3)$$

$$V_{\pi}(s_4) = R(s_4) + \gamma V_{\pi}(s_1)$$

$$V_{\pi}(s_5) = R(s_5) + \gamma V_{\pi}(s_2)$$

$$V_{\pi}(s_6) = R(s_6) + \gamma V_{\pi}(s_5)$$

Otrzymujemy układ równań z 6 niewiadomymi

$$\begin{pmatrix} 1 & -\gamma & 0 & 0 & 0 & 0 \\ 0 & 1 & -\gamma & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ -\gamma & 0 & 0 & 1 & 0 & 0 \\ 0 & -\gamma & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & -\gamma & 1 \end{pmatrix} \begin{bmatrix} v_{\pi}(s_1) \\ v_{\pi}(s_2) \\ v_{\pi}(s_4) \\ v_{\pi}(s_5) \\ v_{\pi}(s_6) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

Szukamy wartości stanów $v_{\pi}(s_i)$. Rozwiązujemy równanie wyznaczając macierz odwrotną do A i mnożąc razy b, gdzie A jest macierzą współczynników układu.

Polecenie

Zapoznaj się z kodem **02-Solving-the-Bellman-equation-for-arbitrary-2D-grid-world.ipynb**

Stwórz własny świat na siatce (np. 3X3 lub 3X4) ze stanem z nagrodą (czerwony kolor, nagroda 1) i stanem zabronionym (niebieski kolor, kara -1).

Zbadaj, jakie są wartości stanów dla różnych wartości γ .

Polecenia

Zapoznaj się z notatnikami

- Ćw. 11_Równanie Bellmana strategia1.ipynb
- Ćw. 11_Równanie Bellmana strategia2.ipynb

(Zbadaj, jakie są wartości stanów dla różnych wartości γ)

- **03-compyting the optimal policy....ipynb** i jego modyfikacją **Ćw. 11_Iteracja wartości.ipynb**

Polecenie

Na podstawie **Ćw. 11_Iteracja wartości.ipynb** wyznacz strategię optymalną dla świata na siatce danego poniżej:

positive_reward (niebieski) = 1.0

negative_reward (pomarańczowy) = -1.0

Rozwiązanie umieść na Moodlu

	1	2	3	4	5
1					
2					
3					
4					
5					

Zapoznaj się z pozostałymi zadaniami 11.-1, 11_2.